

RELATÓRIO DE EVOLUÇÃO DO PROJETO

Projeto: ChargeGrid GoodWe Intelligence – Linha HCA G2

Fase: Sprint 03

1. Resumo da Evolução

Nas Sprints 1 e 2, o sistema conversacional operava de forma procedural dentro de um notebook no Google Colab. As chamadas ao LLM eram lineares, o fatiamento de strings era utilizado para buscar dados, e o histórico era manipulado em listas manuais do Python. Agora, na Sprint 03, o ecossistema foi refatorado para um **projeto local e modular**. A arquitetura utiliza a stack do Módulo 1 (LangChain LCEL), implementando *context engineering* com XML tagging, memória conversacional restrita por tokens e validação rigorosa de saídas (Structured Output) via Pydantic v2.

2. Refatoração: Decisões Técnicas e Trade-offs

A transição do núcleo conversacional procedural para pipelines declarativas com *LangChain Expression Language* (LCEL) baseou-se na premissa de escalabilidade e confiabilidade.

- **Trade-off de Complexidade vs. Estrutura:** A decisão de abandonar a simplicidade do Colab e adotar múltiplos diretórios (src/chain, src/schemas, src/guardrails) exigiu uma curva de aprendizado maior e aumento na complexidade do código com os conteúdos aprendidos no segundo semestre, o código agora conta com validação nativa de formato (Pydantic v2) eliminou quebras de layout nas respostas, e os interceptadores em Python (Guardrails) isolaram a camada de segurança antes mesmo do acionamento do LLM.
- **Gestão de Memória:** Para atender aos requisitos, abandonamos listas manuais e implementamos a integração de `RunnableWithMessageHistory` orquestrada pelo podador de contexto (`trim_messages`). Isso evitou falhas por estouro de limite de tokens nas chamadas de longa duração.

3. Tabela Comparativa Antes/Depois (Obrigatória)

Métrica	Sprints 1/2 (versão manual/legado)	Sprint 03 (LCEL)
Qualidade das respostas (nota no eval)	7.0 (Sujeita a alucinações e respostas genéricas)	10.0 (Zero violações; XML Tagging direcionou a persona)
Tokens por turno	Não mensurado sistematicamente	275 tokens/turno (via tiktoken)
Latência média	Não documentado	1.73 segundos/resposta
Acurácia do structured output	Baixa / Texto livre com formatação imprevisível	100% de aderência ao JSON via <i>parser</i> do Pydantic v2

4. Problemas Encontrados e Soluções

Durante o desenvolvimento e migração para a arquitetura local, a equipe lidou com os seguintes obstáculos técnicos:

- **Problema 1: Erro de Autorização (Status Code 401)**
 - *Decisão Tomada:* Gerar uma nova chave API.
 - *O porquê:* A chave provavelmente era antiga e estava expirada.
- **Problema 2: Falha na Resolução de Módulos (ModuleNotFoundError)**
 - *Decisão Tomada:* Transformar os diretórios em pacotes Python através da adição de arquivos `__init__.py` e reajustar o ponto de execução para a raiz do repositório (ex: `python -m evals.eval_runner`).
 - *O porquê:* O interpretador do Python falhava ao localizar scripts internos ao tentar rodá-los isoladamente. A estruturação formal de pacotes garantiu que imports absolutos funcionassem.

5. Equipe e Divisão de Tarefas

Nome do Aluno	RM (Registro)	Tarefa Principal
Julia Johanson	RM: 572220	Refatoração LCEL, Pydantic v2, Integração de Memória e Construção de Guardrails
Lucas Bomfim	RM: 570420	Context Engineering, XML Tagging e Interface Gradio
Eduardo Barcelos	RM: 573274	Script de Evals, Tabela Comparativa, Relatório e Tratamento de Exceções